

HTTPステータスコード入門

Google Cloud/FastAPI開発で最初に覚えるポイント

1. HTTPステータスコードとは

HTTPリクエストに対して、サーバーが返す結果を表す3桁の番号です。まずは最初の1桁で分類します。

- 1xx: 処理中 (最初は暗記不要)
- 2xx: 成功
- 3xx: 転送・キャッシュ
- 4xx: リクエスト、認証、権限などクライアント側の問題
- 5xx: アプリ、依存サービス、基盤などサーバー側の問題

2. まず覚える代表コード

2xx: 成功

- 200 OK — 取得・処理が成功。例: GET /health、GET /tickets
- 201 Created — 新しいデータの作成に成功。例: POST /tickets
- 202 Accepted — 受付は完了したが、処理はまだ終わっていない。非同期処理で使用
- 204 No Content — 成功したが、返す本文はない

3xx: 転送・キャッシュ

- 301 / 308 — 恒久的な転送
- 302 / 307 — 一時的な転送
- 304 Not Modified — 内容が変わっていないため、キャッシュを再利用

4xx: クライアント側の問題

- 400 Bad Request — JSONやパラメータの形式が不正
- 401 Unauthorized — 認証情報がない、または無効
- 403 Forbidden — 認証できても権限がない。例: Cloud Runの呼び出し権限不足
- 404 Not Found — URLや指定したリソースが存在しない
- 405 Method Not Allowed — GET、POSTなどのHTTPメソッドが違う
- 409 Conflict — 重複登録など、現在の状態とリクエストが競合
- 422 Unprocessable Content — 形式は読めるが入力値が不正。FastAPIの入力検証でよく発生
- 429 Too Many Requests — リクエスト過多、割り当て、レート制限などに到達

5xx: サーバー側の問題

- 500 Internal Server Error — アプリ内部の未処理エラー
- 502 Bad Gateway — 中継先から正しい応答を受け取れない
- 503 Service Unavailable — 一時的に利用不可。容量、コンテナ、依存サービスなどを確認
- 504 Gateway Timeout — 処理や接続先の応答がタイムアウト

3. このプロジェクトでの使い方

- GET /health → 200: APIが稼働中

- POST /tickets → 201: チケット作成成功
- 入力値が不正 → 422: FastAPIの入力検証エラー
- 指定したチケットがない → 404
- Pub/Subへの発行に失敗 → 503
- Pub/Sub Workerの処理成功 → 204: 再配信を止める成功応答
- 非公開Cloud Runを呼べない → 401 / 403: 認証情報とIAM権限を確認

4. Pub/Sub pushで特に重要

- Pub/Subは102、200、201、202、204を受け取ると「処理成功」と判断します。
- それ以外のコード、または応答期限切れでは再配信されます。
- 同じメッセージが複数回来る可能性があるため、Workerは重複しても結果が壊れない設計にします。

5. エラー調査の順番

1. 最初の1桁を確認し、4xxか5xxかを切り分ける
2. 4xxならURL、入力値、認証、IAM、割り当てを確認する
3. 5xxならアプリログ、例外、依存サービス、メモリ、スケーリング、タイムアウトを確認する
4. Cloud Loggingで、ステータスコードと直前のエラーログを一緒に見る
5. 一時的な429、502、503、504は、必要に応じて指数バックオフで再試行する

6. 最小暗記セット

- 2=成功、4=リクエスト・認証・権限、5=サーバー・サービス
- 401=認証できない、403=権限がない
- 404=ない、422=入力値が不正、429=多すぎる
- 500=内部エラー、503=一時利用不可、504=タイムアウト

参考資料

- RFC 9110 (HTTP Semantics)
- Google Cloud: Pub/Sub Push subscriptions
- Google Cloud: Cloud Run troubleshooting